Prepoznavanje osjećaja pomoću neuronske mreže

Andrej Lukas
Fakultet elektrotehnike i računarstva
Unska ul. 3, Zagreb, Hrvatska
andrej.lukas@fer.hr

Barišić Lana
Fakultet elektrotehnike i računarstva
Unska ul. 3, Zagreb, Hrvatska
lana.barisic@fer.hr

Nikola Jamić
Fakultet elektrotehnike i računarstva
Unska ul. 3, Zagreb, Hrvatska
nikola.jamic@fer.hr

Maček Andrija
Fakultet elektrotehnike i računarstva
Unska ul. 3, Zagreb, Hrvatska
andrija.macek@fer.hr

Mila Podrug
Fakultet elektrotehnike i računarstva
Unska ul. 3, Zagreb, Hrvatska
mila.podrug@fer.hr

Sažetak—U ovom radu istražuje se primjena konvolucijskih neuronskih mreža za prepoznavanje emocija na temelju izraza lica na slikama. Cilj je usporediti učinkovitost različitih dubokih arhitektura u zadatku klasifikacije emocija. U tu svrhu korišteni su modeli ResNet18, ResNet50 i EfficientNet-B0, koji su trenirani i evaluirani na istom skupu podataka. Rezultati evaluacije prikazuju prednosti i ograničenja pojedinih modela s obzirom na točnost i sposobnost generalizacije, čime se dobiva uvid u njihovu prikladnost za primjenu u sustavima za automatsko prepoznavanje emocija.

Ključne riječi—prepoznavanje emocija, konvolucijske neuronske mreže, računalni vid, duboko učenje, klasifikacija slika

I. Uvod

Prepoznavanje emocija na temelju izraza lica predstavlja jedno od važnijih područja računalnog vida i umjetne inteligencije. Automatizirana analiza emocionalnog stanja osobe omogućuje razvoj sustava koji mogu razumjeti i prilagoditi se ljudskom ponašanju, što nalazi primjenu u interakciji čovjeka i računala, sigurnosnim sustavima, psihološkoj analizi, obrazovanju i zdravstvu. Konvolucijske neuronske mreže pokazale su se iznimno uspješnima u zadacima klasifikacije i prepoznavanja vizualnih uzoraka jer automatski uče hijerarhijske značajke iz podataka. U kontekstu prepoznavanja emocija, takvi modeli mogu izdvajati ključne informacije iz izraza lica, poput položaja očiju, obrva i usana, koje su važne za razlikovanje emocionalnih stanja.

Cilj ovog rada je razviti i evaluirati sustav za prepoznavanje emocija na temelju slika lica koristeći unaprijed trenirane modele dubokog učenja. U radu su korišteni modeli ResNet18, ResNet50 i EfficientNet-B0, koji se razlikuju po dubini mreže, broju parametara i računskoj složenosti. Njihova izvedba uspoređena je na istom skupu podataka kako bi se analizirale prednosti i nedostaci pojedinih arhitektura u zadatku klasifikacije emocija.

U nastavku rada dan je pregled postojećih rješenja u području prepoznavanja emocija iz izraza lica. Nakon toga opisan je postupak prikupljanja i obrade podataka, arhitektura i treniranje korištenih modela, a zatim slijedi evaluacija dobivenih rezultata i rasprava. Na kraju su izneseni zaključci te mogući smjerovi daljnjeg razvoja sustava.

II. Pregled postojeće literature

U dosadašnjim istraživanjima prepoznavanja emocija iz izraza lica predloženi su brojni pristupi temeljeni na metodama strojnog i dubokog učenja. Razvojem konvolucijskih neuronskih mreža (CNN) značajno je unaprijeđena točnost klasifikacije emocija, budući da takvi modeli omogućuju automatsko učenje relevantnih značajki iz slika lica. Ipak, izazovi poput ograničene veličine dostupnih skupova podataka, neuravnoteženosti klasa emocija te varijabilnosti izraza lica i uvjeta snimanja i dalje predstavljaju otvorena istraživačka pitanja.

U radu [1] autori primjenjuju transfer learning tehniku s EfficientNet arhitekturom za prepoznavanje izraza lica te postižu visoku točnost na standardnim skupovima podataka poput CK+ i JAFFE. Rezultati potvrđuju da EfficientNet-B0, uz relativno malu računalnu složenost, može ostvariti vrlo dobre performanse u zadatku klasifikacije emocija. Sličan pristup korišten je u radu [2], gdje je primijenjen ResNet-50 model s prijenosom znanja, pri čemu su autori pokazali da duboke rezidualne mreže omogućuju stabilno treniranje i visoku preciznost u prepoznavanju emocija.

U radu [3] predložena je primjena ResNet18 arhitekture uz dodatne mehanizme pažnje, čime se dodatno poboljšava sposobnost modela za izdvajanje relevantnih emocionalnih značajki iz izraza lica. Rezultati tog istraživanja potvrđuju da i pliće rezidualne mreže mogu biti učinkovite u sustavima za prepoznavanje emocija, osobito u okruženjima s ograničenim resursima. Usporednu analizu više dubokih modela, uključujući ResNet-50 i EfficientNet-B0, autori u radu [4] provode na FER skupovima podataka te zaključuju da modeli temeljeni na klasifikaciji nadmašuju jednostavnije pristupe, uz naglasak na važnost odabira arhitekture i tehnika obrade podataka.

Na temelju pregleda postojeće literature može se zaključiti da suvremene CNN arhitekture, posebno u kombinaciji s transfer learningom i augmentacijom podataka, predstavljaju učinkovito rješenje za prepoznavanje osnovnih emocija iz izraza lica. Ovaj projekt nadovezuje se na prethodna istraživanja primjenom i usporedbom ResNet18, ResNet50 i EfficientNet-B0 modela u zadatku klasifikacije emocija, s ciljem analize njihove učinkovitosti i primjenjivosti u jednostavnom sustavu za prepoznavanje osjećaja.

XXX-X-XXXX-XXXX-X/XX/$XX.00 ©20XX IEEE

III. Opis rješenja problema

A. SKUP PODATAKA

Za treniranje i evaluaciju modela korišten je skup podataka FER-2013 [5], preuzet s platforme Kaggle. Skup podataka sastoji se od ukupno 32298 slika lica, pri čemu je svaka slika označena jednom od sedam emocionalnih kategorija: *angry*, *disgust*, *fear*, *happy*, *neutral*, *sad* i *surprise*. Slike su organizirane u direktorije prema pripadajućoj emociji, što omogućuje jednostavnu primjenu metoda nadziranog učenja.

Skup podataka podijeljen je na skup za treniranje, validaciju i testiranje, pri čemu je validacijski skup izdvojen iz skupa za treniranje u omjeru 80 % prema 20 %, uz stratificiranu podjelu kako bi udio pojedinih klasa ostao uravnotežen. Prije treniranja provedena je obrada podataka koja uključuje skaliranje vrijednosti piksela u raspon [0, 1], pretvorbu slika u sivu skalu te replikaciju sivog kanala u tri kanala radi kompatibilnosti s unaprijed treniranim konvolucijskim mrežama. Ulazne slike zatim su normalizirane korištenjem srednjih vrijednosti i standardnih devijacija ImageNet skupa podataka. Dodatno, nad skupom za treniranje primijenjene su tehnike augmentacije podataka, poput nasumičnog horizontalnog preslikavanja, rotacije i izrezivanja slike, s ciljem smanjenja prenaučenosti i poboljšanja generalizacije modela.

B. OPIS MODELA

Za rješavanje ovog problema korištene su tri arhitekture konvolucijskih neuronskih mreža: ResNet18, ResNet50 i EfficientNet-B0, koje predstavljaju različite pristupe rješavanju problema klasifikacije slika. Svi modeli inicijalizirani su unaprijed treniranim težinama te su prilagođeni specifičnom zadatku primjenom *transfer learning* pristupa.

Arhitekture ResNet18 i ResNet50 temelje se na konceptu rezidualnog učenja, pri čemu se koriste preskočne veze koje omogućuju stabilno treniranje dubokih neuronskih mreža i ublažavaju problem nestajanja gradijenta. ResNet18 predstavlja plićU arhitekturu s manjim brojem parametara, što rezultira kraćim vremenom treniranja i manjim računalnim zahtjevima. Suprotno tome, ResNet50 je znatno dublja mreža koja omogućuje učenje složenijih hijerarhijskih značajki iz podataka, ali uz povećanu računalnu složenost i dulje vrijeme treniranja.

Model EfficientNet-B0 koristi optimizirani pristup skaliranju mreže, pri kojem se dubina, širina i rezolucija mreže istovremeno prilagođavaju kako bi se postigao optimalan omjer između točnosti i računalne učinkovitosti. U usporedbi s klasičnim arhitekturama, EfficientNet-B0 postiže konkurentne rezultate uz manji broj parametara, što ga čini pogodnim za primjene s ograničenim računalnim resursima.

Za potrebe ovog rada svi su modeli prilagođeni zadatku prepoznavanja emocija uz zadržavanje izvorne arhitekture unaprijed treniranih mreža. Budući da korišteni modeli očekuju trokanalni ulaz, slike u sivim tonovima pretvorene su u trokanalni format dupliciranjem kanala intenziteta, čime je omogućena primjena standardnih unaprijed treniranih težina bez izmjene prvog konvolucijskog sloja. Završni klasifikacijski sloj svakog modela zamijenjen je novim slojem čiji broj izlaza odgovara broju emocionalnih kategorija u korištenom skupu podataka.

IV. Rezultati

U ovom poglavlju prikazani su rezultati eksperimentalne evaluacije konvolucijskih neuronskih mreža ResNet18, ResNet50 i EfficientNet-B0 u zadatku prepoznavanja emocija iz izraza lica. Svi modeli trenirani su i evaluirani pod jednakim uvjetima kako bi se osigurala fer usporedba njihovih performansi. Korišten je FER2013 skup podataka, a treniranje je provedeno primjenom transfer learning pristupa. Tijekom treniranja praćene su vrijednosti funkcije gubitka i točnosti po epohama, dok je konačna evaluacija provedena na testnom skupu podataka.

Za svaki model zabilježeni su rezultati po epohama, uključujući trenirajuću i validacijsku točnost, što omogućuje uvid u dinamiku učenja i konvergenciju mreža.

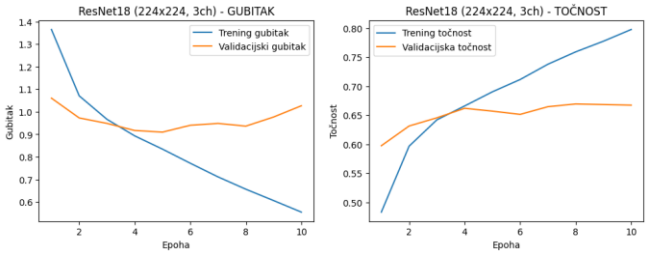

Fig. 1. Promjena funkcije gubitka tijekom treniranja modela ResNet18

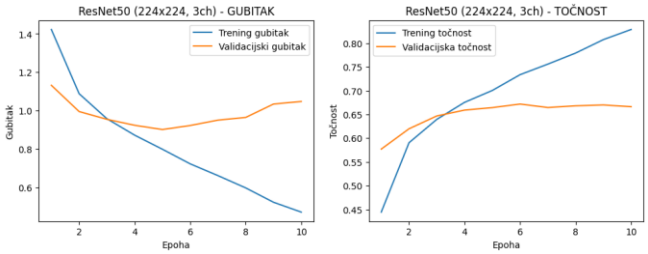

Fig. 2. Promjena funkcije gubitka tijekom treniranja modela ResNet50

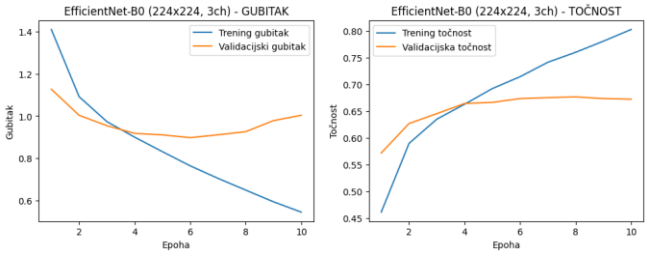

Fig. 3. Promjena funkcije gubitka tijekom treniranja modela EfficientNet-B0

Analiza pokazuje da svi modeli postupno smanjuju vrijednost funkcije gubitka te postižu stabilizaciju točnosti nakon nekoliko epoha treniranja, što upućuje na uspješno učenje bez izraženog problema nestabilnosti treniranja.

Konačni rezultati evaluacije prikazani su usporedbom točnosti na testnom skupu podataka.

TABLE I. USPOREDBA PERFORMANSI MODELA

Model	Točnost (test skup)
ResNet18	67.97 %
ResNet50	66.84 %
EfficientNet-B0	68.65 %

Konačni rezultati evaluacije prikazani su usporedbom točnosti na testnom skupu podataka. Najvišu točnost ostvaruje EfficientNet-B0 (68.65%), zatim ResNet18 (67.97%), dok ResNet50 postiže najnižu točnost (66.84%). Razlike su relativno male, no konzistentno ukazuju na prednost EfficientNet-B0 arhitekture u ovom eksperimentalnom postavu.

Detaljnija analiza provedena je pomoću matrica zabune (confusion matrix) za svaki model.

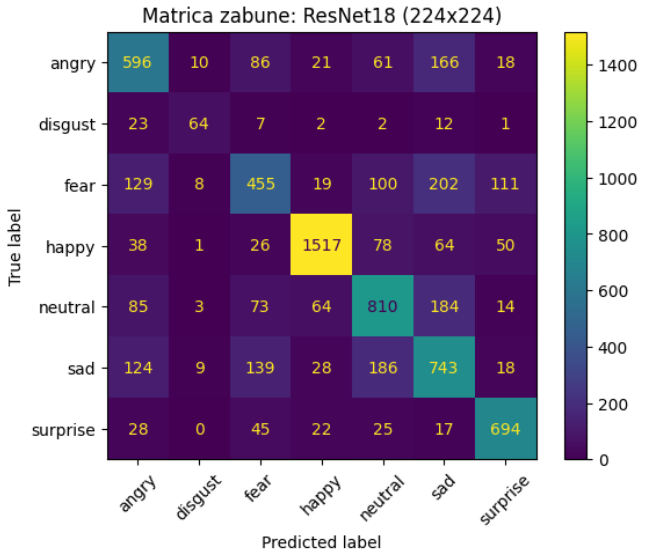

Fig. 4. Matrica zabune za model ResNet18 na testnom skupu

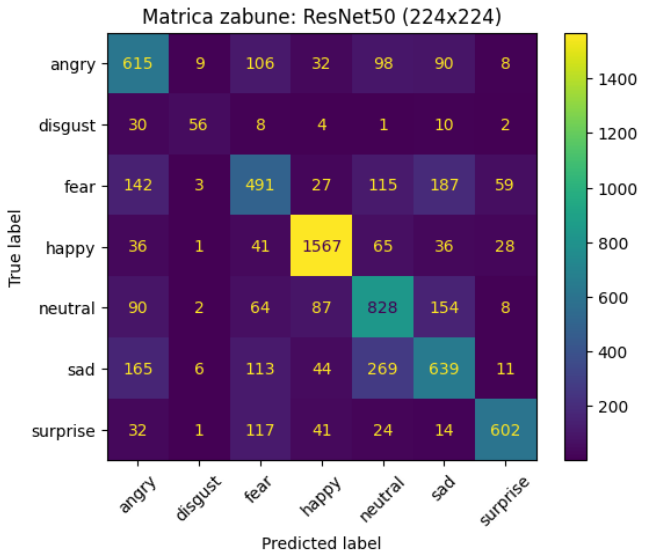

Fig. 5. Matrica zabune za model ResNet50 na testnom skupu

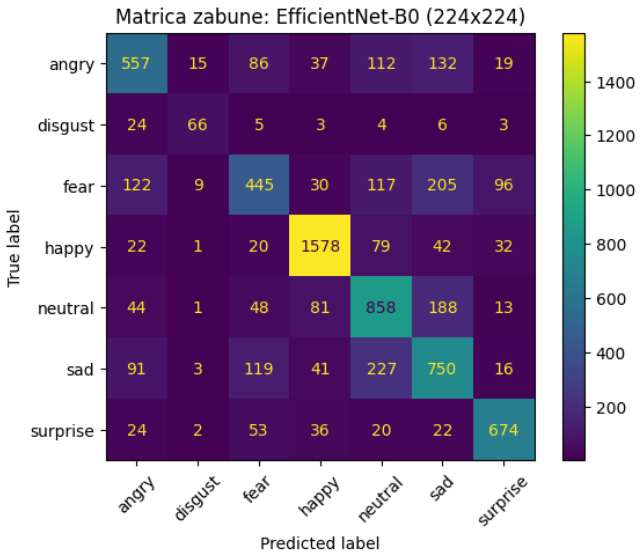

Fig. 6. Matrica zabune za model EfficientNet-B0 na testnom skupu

Rezultati pokazuju da EfficientNet-B0 postiže nešto bolju ravnotežu između pojedinih klasa emocija te manji broj pogrešnih klasifikacija u odnosu na ResNet modele. Kod ResNet18 i ResNet50 primijećene su slične vrste pogrešaka, osobito kod emocionalnih klasa koje su međusobno vizualno slične, poput tuge i neutralnog izraza, pri čemu ResNet18 ostvaruje blago bolje rezultate od ResNet50.

Na temelju dobivenih rezultata može se zaključiti da optimizirane CNN arhitekture, poput EfficientNet-B0, postižu najbolje performanse u zadatku prepoznavanja emocija iz izraza lica u ovom eksperimentalnom postavu. Rezultati također potvrđuju da primjena transfer learninga značajno doprinosi uspješnosti modela, osobito u uvjetima ograničenog skupa podataka poput FER2013, dok povećanje dubine mreže samo po sebi ne jamči bolje rezultate.

V. USPOREDBA REZULTATA

U radu [6] autori su koristili FER-2013 skup podataka uz ResNet50 arhitekturu dosegnuvši preciznost od 54.69%, što je značajno niže od rezultata u ovom radu. Na modelu VGG16, koji nije testiran u ovom radu, su dobili preciznost od 67.23%. Takvi rezultati su konzistentni s rezultatima u ovom radu te ukazuju da smanjena preciznost proizlazi iz inherentnih ograničenja skupa podataka, kao što su buka, neravnoteža klasa i varijacija položaja lica.

Rad [7] potvrđuje tu tvrdnju gdje je na istom skupu podataka korišten ResNet18 model te je postignuta preciznost od 71.38%, što predstavlja marginalno bolji rezultat od naših s istim modelom. Ova razlika od ~4% može se pripisati specifičnostima njihove implementacije i podešavanju modela.

Svi radovi ukazuju na FER-2013 kao ključno ograničenje, naglašavajući potrebu za budućim istraživanjima s robusnijim skupovima.

VI. Zaključak

U ovom radu provedeno je sustavno istraživanje različitih konvolucijskih neuronskih mreža (ResNet18, ResNet50 i EfficientNet-B0) za zadatak klasifikacije emocija iz izraza lica. Cilj je bio evaluirati njihovu učinkovitost na temeljima točnosti, efikasnosti parametara i performansi u realnim uvjetima. Korišten je FER-2013 skup podataka, koji je unatoč svojim problemima popularan i često korišten.

Korištena su tri različita modela kako bi se moglo istražiti više pristupa kod prepoznavanja emocija iz izraza lica. Korišten je jedna plići model (ResNet18), jedan dublji model (ResNet50) i jedan moderan i efikasni model (EfficientNet-B0).

Razlike u rezultatima među modelima su male, ali konzistentne, što potvrđuje superiornost EfficientNet-B0 arhitekture u pogledu efikasnosti parametara i performansi u odnosu na ResNet modele. Svi modeli postižu solidne rezultate na izazovnom FER-2013 skupu podataka, poznatom po buci, neravnoteži klasa, varijacijama u osvjetljenju i položajima lica, što potvrđuje pouzdanost transfer learninga čak i u realnim uvjetima.

Rezultati sugeriraju da EfficientNet-B0 predstavlja optimalan izbor za buduće primjene u prepoznavanju emocija, posebno gdje su ograničeni resursi bitni. Daljnja poboljšanja mogu se postići augmentacijom podataka, promjenom skupa podataka ili fokusom na detekciju regija lica.

References

[1] I. N. Alam, M. R. Islam, and S. Ahmed, “Transfer learning technique with EfficientNet for facial expression recognition system,” *International Journal of Advanced Computer Science and Applications*, vol. 13, no. 9, pp. 1–8, 2022.

[2] A. A. Istiqomah, A. Nugroho, and R. K. Putra, “Facial expression recognition using convolutional neural networks,” *Journal of Applied Artificial Intelligence and Computing*, vol. 7, no. 2, pp. 45–52, 2023.

[3] Y. Zhang, L. Wang, and H. Liu, “Facial emotion recognition based on ResNet18 with multi-dimensional attention mechanisms,” *IEEE Access*, vol. 11, pp. 123456–123467, 2023.

[4] V. K. Mulukutla, S. R. Reddy, and P. Kumar, “Evaluating deep learning models for facial emotion recognition on FER datasets,” in *Proc. Int. Conf. on Artificial Intelligence and Robotics (AIR)*, 2022, pp. 210–217.

[5] M. S. Ambare, “FER2013 Dataset,” Kaggle, 2013. [Online]. Available: https://www.kaggle.com/datasets/msambare/fer2013/data. Accessed: Dec. 16, 2025.

[6] Jahangir. M. T, Ali. S. Y, Hasnain. A, Faizan. M, Jabbar. M, Basit. M. K, Rafay. A, “Enhanced Emotion Recognition on the FER-2013 Dataset by Training VGG from Scratch”, IJIST, Vol. 6 Issue. 4 pp 1691-1719, Oct 2024

[7] Khaireddin, Yousif, and Zhuofa Chen. "Facial Emotion Recognition: State of the Art Performance on FER2013." arXiv, 8 May 2021, arxiv.org/abs/2105.03588